
بسم الله الرحمن الرحيم

دانشگاه صنعتی اصفهان

دانشکده مهندسی برق و کامپیوتر

پروژه درس کامپایلر

طراحی کامپایلر برای زبان برنامه نویسی Xlang

استاد درس

دکتر زینب زالی

ترم ۴۰۰۲

فهرست مطالب

عنوان **صفحه**

تعریف پروژه

در این پروژه قصد داریم یک کامپایلر برای زبانی به نام $Xlang$ طراحی و پیاده سازی کنیم. $Xlang$ یک زبان دستوری ساده شبیه به C یا $Pascal$ است. پیاده سازی این کامپایلر با استفاده از دو ابزار $Bison$ و $Flex$ انجام می شود و کامپایلر هدف باید بتواند یک فایل حاوی کد نوشته شده به زبان $Xlang$ را دریافت کرده و با در نظر گرفتن سه بخش تحلیل لغوی[1]، نحوی[2] و معنایی [3] و دیگر مفاهیم لازم که در درس کامپایلر مطالعه خواهید کرد یک کد خروجی به زبان اسمبلی تولید نماید.

هدف از طراحی این پروژه این است که کامپایلر مذکور را قدم به قدم و همگام با مطالبی که در درس می‌آموزید پیاده سازی کنیم تا با جنبه‌های عملی نوشتن یک کامپایلر ابتدایی، آشنا شوید.

[1] Lexical Analysis
[2] Syntax Analysis
[3] Semantic Analysis

فصل اول

تحلیلگر لغوی

۱ـ۱ هدف

در این فاز از پروژه می‌بایست یک تحلیلگر لغوی را با استفاده از ابزار $flex$ نوشته و در محل مشخص شده درون سامانه آپلود کنید.

جهت ارزیابی، یک فایل حاوی قطعه کدی به زبان $Xlang$ که در ادامه توصیف خواهد شد به تحلیلگر لغوی شما داده می‌شود، در صورتی که کد برنامه قواعد لغوی زبان برنامه نویسی $Xlang$ را رعایت کرده باشد، شما باید در خروجی، توکن‌های آن برنامه را چاپ کنید و در غیر این صورت ، بعد از مواجه شدن با خطا، بدون تولید هرگونه توکنی، می‌بایست خطای مناسب چاپ گردد.

۱ـ۲ حساسیت به حروف کوچک و بزرگ

تمام کلمات کلیدی در زبان $Xlang$ با حروف کوچک نوشته می‌شوند. کلمات کلیدی و شناسه‌ها [1] حساس به حروف کوچک و بزرگ هستند [2] مثلاً `if` یک کلمه کلیدی هست ولی `IF` نام یک متغیر است یا به طور مثال `foo` و `Foo` دو نام متفاوت برای اشاره به دو متغیر متفاوت هستند.

[1] Identifiers
[2] Case-Sensitive

۱ـ۳ کلمات کلیدی

در زبان $Xlang$ کلمات کلیدی شامل موارد زیر است :

```
boolean    break    callout    class    continue    else    for    if
false      return   true       void     int
```

۱ـ۴ متغیرها

در زبان $Xlang$ متغیرها [۱] ترکیبی از حروف، اعداد انگلیسی و خط تیره [۲] هستند که حتما باید با یک حرف و یا خط تیره آغاز شوند و هیچ متغیری نمی‌تواند با عدد آغاز شود.

۱ـ۵ کامنت

کامنت‌ها با // شروع می‌شوند و با پایان خط [۳] خاتمه می‌یابند.
توجه ! اصولاً کامنت ها به وسیله preprocessor پردازش می‌شوند و کامپایلر وظیفه پردازش آنها را ندارد، اما چون در این پروژه ، preprocessor وجود ندارد باید به وسیله‌ی تحلیلگر لغوی پردازش شوند.

۱ـ۶ مقادیر ثابت

۱ـ۶ـ۱ رشته و کاراکتر

رشته‌ها ترکیبی از ⟨char⟩ها هستند که در داخل "" قرار می‌گیرد.
یک کاراکتر شامل یک ⟨char⟩ است که در داخل '' قرار می‌گیرد.
منظور از ⟨char⟩ هر کاراکتر اسکی قابل چاپ (کاراکترهایی که کد اسکی نظیر آنها از ۳۲ تا ۱۲۶ است به جز کاراکترهای single quote (') ، backslash (\) و double quote (")) به علاوه پنج دنباله کاراکتری شامل ('\') برای نمایش single quote ، (\\) برای نمایش backslash ، ("\") برای نمایش double quote ، (\n) برای نمایش newline و (\t) برای نمایش tab می‌باشد.

۱ـ۶ـ۲ اعداد

اعداد در زبان $Xlang$ ۳۲ بیتی و علامت‌دار هستند. همچنین در زبان $Xlang$ فقط با اعداد صحیح [۴] کار می‌کنیم. اعداد صحیح به یکی از دو فرم زیر بیان می‌شوند :

---
[1] Variables
[2] Underscore OR _
[3] Newline OR $\backslash n$
[4] Integer

- دسیمال[1] : مقادیر دسیمال از 2147483648− تا 2147483647 است.
- هگزا دسیمال[2] : اگر یک دنباله با 0x آغاز شود و بعد از آن دنباله‌ای از کاراکترهای نشأت گرفته شده از [a-fA-F0-9] بیاید آنگاه دنباله مذکور بیانگر یک عدد هگزا دسیمال است.

۱ـ۷ عملگرها

عملگرهایی که در زبان ورودی مجاز هستند شامل عملگرهای محاسباتی، منطقی و شرطی می‌شوند که لیست آنها در زیر آمده است :

```
+   -   *   /   %   <   >   !=   <=   >=   ==   &&   ||   !   =   -=   +=
```

۱ـ۸ توکن‌های خاص

توکن‌های خاص به توکن‌هایی گفته می‌شود که نه متغیر هستند نه کلمه کلیدی و نه عملگر که لیست آنها در زیر آمده است :

```
(  )    {  }    [  ]    ;    ,
```

۱ـ۹ تشخیص توکن‌ها

توکن‌ها از طریق فاصله [3] و یا از طریق توکن‌های خاص از هم جدا می‌شوند.
توجه ! هر تعداد فاصله که بین دو توکن وارد شود بی‌تاثیر است و باید نادیده گرفته شود.

۱ـ۱۰ خروجی تحلیلگر لغوی

همانگونه که پیش تر اشاره شد، چنانچه یک برنامه‌ی صحیح به تحلیلگر شما داده شود باید بتواند توکن‌های آن را استخراج کند. به منظور استخراج توکن‌ها از برنامه ورودی، تنها نام آن توکن و مقدار آن را در خروجی چاپ نمایید (ابتدا نام توکن و سپس مقدار آن).

---
[1] Decimal
[2] Hexadecimal
[3] Whitespace: Tab, Space, ···

خروجی تحلیلگر لغوی شما برای یک نمونه کد صحیح به صورت زیر خواهد بود :

```
Input Code :
    int x;
    x = 5;

Analyzer Output :
    TOKEN_INTTYPE int
    TOKEN_WHITESPACE [space]
    TOKEN_ID x
    TOKEN_SEMICOLON ;
    TOKEN_WHITESPACE [newline]
    TOKEN_ID x
    TOKEN_WHITESPACE [space]
    TOKEN_ASSIGNOP =
    TOKEN_WHITESPACE [space]
    TOKEN_DECIMALCONST 5
    TOKEN_SEMICOLON ;
```

خروجی تحلیلگر لغوی شما برای یک نمونه کد حاوی خطا به صورت زیر خواهد بود :

```
Input Code :
    int 9comp;
    9comp = 3;

Analyzer Output :
    TOKEN_INTTYPE int
    TOKEN_WHITESPACE [space]
    error in line 1 : wrong id definition
```

در پیوست ۱ لیست کلیه توکن‌های موجود در زبان $Xlang$ همراه با نام هر توکن آورده شده است.

توجه ! دو توکن `main` و `Program` در فاز بعدی به تفصیل شرح داده خواهند شد.

۱ـ۱۱ بخش امتیازی

درصورتی که تحلیلگر لغوی شما بتواند بعد از مواجه شدن با خطا ضمن چاپ پیغام مناسب ، از خطای موجود عبور کرده و مابقی توکن‌ها را نیز استخراج کند، نمره امتیازی کسب خواهید کرد.

فصل دوم

تحلیلگر نحوی

۲ـ۱ هدف

در این فاز از پروژه می‌بایست یک تحلیلگر نحوی را با استفاده از ابزار $bison$ نوشته و در محل مشخص شده درون سامانه آپلود کنید.

جهت ارزیابی، یک فایل حاوی قطعه کدی به زبان $Xlang$ که در ادامه ساختار جملات آن توصیف خواهد شد به تحلیلگر نحوی شما داده می‌شود، در صورتی که کد برنامه قواعد نحوی زبان برنامه نویسی $Xlang$ را رعایت کرده باشد، شما باید در خروجی، $Syntax\ Tree$ آن برنامه را چاپ کنید و در غیر این صورت ، بعد از مواجه شدن با خطا، بدون تولید هیچ درختی، می‌بایست خطای مناسب چاپ گردد.

لازم به ذکر است این تحلیلگر نحوی می بایست توکن های برنامه را از خروجی تحلیلگر لغوی پیاده سازی شده در فاز پیشین دریافت نماید.

۲ـ۲ قواعد نحوی زبان

یک برنامه نوشته شده به زبان $Xlang$ شامل کلاسی تحت عنوان Program می باشد که از دو بخش field declaration و method declaration تشکیل شده است. بخش field declaration حاوی تعریف متغیرهایی

است که به صورت سراسری توسط تمامی متدهای برنامه قابل دسترسی و استفاده هستند و بخش method declaration حاوی تعریف توابع برنامه می باشد. کلاس Program الزماً می بایست شامل متدی تحت عنوان main بدون هیچ گونه آرگومان ورودی‌ای باشد. لازم به ذکر است نقطه شروع برنامه $Xlang$ متد main خواهد بود.

۲ـ۲ـ۱ نوع داده ها

دو نوع داده اصلی در زبان $Xlang$ تعریف می شود. این دو نوع داده، داده های صحیح و `true` یا `false` هستند که اختصاراً با کلمات کلیدی int و boolean نشان داده می شود.

۲ـ۲ـ۲ متغیر ها و آرایه ها

در زبان $Xlang$ متغیر ها و آرایه هایی از نوع int و boolean قابل تعریف و استفاده هستند و تعریف آن ها به صورت زیر خواهد بود.

```
Variable Declaration:
    int var1, var2, var3;
    boolean v1;

Array Declaration:
    int arr[10];
    boolean a[3], b[5];
```

آرایه ها می بایست تنها در بخش field declaration کلاس Program تعریف شوند و تمامی آرایه ها تک بعدی بوده و آرگومان سایز نظیر آن ها یک مقدار ثابت خواهد بود و این مقدار به صورت ورودی از کاربر دریافت نمی شود. در این زبان هیچ گونه تعریفی برای آرایه های پویا نخواهیم داشت.

۲ـ۲ـ۳ دستورات کنترلی

دستورات کنترلی در زبان $Xlang$ شامل دستورات شرطی و حلقه ها است که در ادامه به شرح آن ها می پردازیم:

دستورات شرطی

شرط `if` ممکن است در کدها وجود داشته باشد. در این صورت ساختار آن به صورت زیر خواهد بود.

```
if (expr) {
    //if body
}
```

به علاوه شرط if ممکن است با else نیز همراه شود در این صورت ساختار آن به صورت زیر خواهد بود.

```
if (expr) {
    //if body
}
else {
    //else body
}
```

حلقه ها

حلقه for ممکن است در کدها وجود داشته باشد در این صورت ساختار آن به صورت زیر خواهد بود.

```
for x = expr , expr {
    //for body
}

for x = 1 , 10 {
    //for body
}
```

در کد فوق متغیر x را اندیس حلقه گوییم. نخستین expr ، شروع حلقه و دومین expr ، انتهای حلقه را معین می سازد برای مثال در حلقه فوق، مقدار اولیه اندیس حلقه برابر 1 قرار داده شده و پس از هر مرتبه اجرای حلقه یک واحد به مقدار این اندیس افزوده می گردد تا زمانی که اندیس حلقه از مقدار 10 کوچکتر باشد دستورات موجود در بدنه اجرا خواهند شد.

لازم به ذکر است expr می تواند هر عبارتی باشد که معادل یک عدد صحیح است. برای مثال می تواند خروجی یک تابع یا حاصل یک عملیات ریاضیاتی نیز باشد.

۲ـ۲ـ۴ توابع و متدها

متدها می توانند حداکثر چهار آرگومان ورودی داشته باشند. در صورتی که یک متد بیش از چهار آرگومان ورودی داشته باشد به منزله نقض قواعد زبان است.

بدین صورت تعریف و فراخوانی متدها به صورت زیر خواهد بود.

```
Method Declaration:

    int method_name(int agr1, boolean arg2) {
        // method body
    }


Method Call:

    method_name(10, true);
```

لازم به ذکر است متدهایی که خروجی ندارند (از نوع void هستند) ضمن فراخوانی تنها می توانند در قالب یک جمله استفاده شوند و قابل استفاده در عبارات نیستند. (برای مثال اگر متد foo دارای خروجی صحیح باشد عبارت 3 + foo(args) یک عبارت معتبر تلقی می شود در حالی که اگر متد foo بدون خروجی باشد تنها می توان این متد را به صورت ; foo(args) و در قالب یک جمله فراخوانی نمود)

همچنین در صورتی که یک متد خروجی داشته باشد می توان از آن هم در قالب بخشی از عبارات و هم در قالب یک جمله استفاده نمود که در اینصورت خروجی آن نادیده گرفته می شود. (برای متد foo که دارای یک خروجی صحیح است هم فراخوانی در قالب یک جمله یعنی ; foo(args) صحیح است و هم فراخوانی در قالب بخشی از یک عبارت همانند 2 + foo(args) - 3)

توجه ! بررسی خروجی متدها مربوط به فاز تحلیلگر معنایی است لذا در این فاز شما تنها می بایست ضمن تعریف گرامر هر دو حالت ذکر شده را در نظر بگیرید.

فراخوانی توابع آماده از کتابخانه‌های مختلف

زبان $Xlang$ دارای یک روش برای فراخوانی توابع آماده در سیستم در زمان اجرای برنامه است ، مانند توابعی در کتابخانه استاندارد زبان C یا توابع تعریف شده توسط کاربر با زبان‌هایی غیر از $Xlang$ که با ابزارهای استاندارد کامپایل شده و موقع اجرا به برنامه $Xlang$ لینک می‌شوند.

در واقع callout خود تابعی آماده در زبان $Xlang$ است که به صورت زیر تعریف شده.

int **callout** (⟨string_literal⟩ [, ⟨callout_arg⟩$^{+}$,])

واضح است که نام تابعی که در کتابخانه‌ای خارج از برنامه فعلی موجود است و قصد فراخوانی آن را داریم به همراه آرگومان‌های مورد نیاز آن به callout پاس داده می‌شوند. عباراتی از نوع int و boolean به صورت عدد صحیح [۱] و رشته ها یا عباراتی از نوع آرایه به صورت اشاره‌گر [۲] به تابع مذکور پاس داده می‌شوند.

همجنین مقدار خروجی تابع مذکور به صورت عدد صحیح بازمی‌گردد و مقدار بازگشتی زمانی معتبر و قابل استفاده است که تابع مذکور در واقع مقداری از نوع مناسب را بازگرداند.

ضمناً بدیهی است که کاربر موظف است به تعداد مورد نیازِ تابعی که قصد فراخوانی آن را دارد ، آرگومان از نوع مناسب از طریق تابع callout به تابع موردنظر پاس دهد.

بدین استفاده از callout به صورت زیر خواهد بود.

```
callout("strcmp", "string 1", "string 2");
```

---

[۱] Integer

[۲] Pointer

۲-۲-۵ عملگرها

عملگر ها در این زبان به دو دسته تک عملوندی [۱] و دو عملوندی [۲] تقسیم می شوند. برای مثال عملگر ! یا همان نقیض یک عملگر تک عملوندی و عملگر && یک عملگر دو عملوندی محسوب می شود.

۲-۳ گرامر مرجع

همانطور که می دانید اصلی ترین بخش یک تحلیلگر نحوی تعریف گرامر مناسب برای زبان ورودی است. بدین منظور گرامر زیر به صورت اولیه برای این زبان تعریف شده است. بدیهی است در مواردی که گرامر مبهم باشد رفع ابهام بخش های مورد نیاز بر عهده شماست.

⟨ foo ⟩	به این معنا که foo غیرترمینال است.
foo	(با خط درشت) به این معنا است که foo ترمینال است.
$[x]$	به این صورت که یک توکن یا بخشی از یک توکن است. به معنای ظاهر شدن حداکثر یک x (صفر یا یک رخداد) است به نحوی که x اختیاری میباشد. توجه داشته باشید که براکت در گیومه ، '[' ']' ، ترمینال است.
x^*	به معنای ظاهر شدن صفر یا بیشتر x است.
x^+,	یک لیست شامل حداقل یک x که با کاما جدا شده باشند.
{}	کروشه بزرگ برای گروه کردن استفاده میشود. توجه داشته باشید که کروشه در گیومه ، '{' '}' ، ترمینال است.
|	عملگر or

[۱] Unary operator
[۲] Binary operator

⟨program⟩ → **class Program** '{' ⟨field_decl⟩* ⟨method_decl⟩* '}'

⟨field_decl⟩ → ⟨type⟩ { ⟨id⟩ | ⟨id⟩ '[' ⟨int_literal⟩ ']' }+, ;

⟨method_decl⟩ → {⟨type⟩ | **void**} {⟨id⟩ | **main**} ([{⟨type⟩ ⟨id⟩}+,]) ⟨block⟩

⟨block⟩ → '{' ⟨var_decl⟩* ⟨statement⟩* '}'

⟨var_decl⟩ → ⟨type⟩ ⟨id⟩+, ;

⟨type⟩ → **int** | **boolean**

⟨statement⟩ → ⟨location⟩ ⟨assign_op⟩ ⟨expr⟩ ;
| ⟨method_call⟩ ;
| **if** (⟨expr⟩) ⟨block⟩ [**else** ⟨block⟩]
| **for** ⟨id⟩ = ⟨expr⟩ , ⟨expr⟩ ⟨block⟩
| **return** [⟨expr⟩] ;
| **break** ;
| **continue** ;
| ⟨block⟩

⟨assign_op⟩ → = | += | -=

⟨method_call⟩ → ⟨method_name⟩ ([⟨expr⟩+,])
| **callout** (⟨string_literal⟩ [, ⟨callout_arg⟩+,])

⟨method_name⟩ → ⟨id⟩

⟨location⟩ → ⟨id⟩
| ⟨id⟩ '[' ⟨expr⟩ ']'

⟨expr⟩ → ⟨location⟩
| ⟨method_call⟩
| ⟨literal⟩
| ⟨expr⟩ ⟨bin_op⟩ ⟨expr⟩
| - ⟨expr⟩
| ! ⟨expr⟩
| (⟨expr⟩)

⟨callout_arg⟩ → ⟨expr⟩ | ⟨string_literal⟩

⟨bin_op⟩ → ⟨arith_op⟩ | ⟨rel_op⟩ | ⟨eq_op⟩ | ⟨cond_op⟩

⟨arith_op⟩ → + | - | * | / | %

⟨rel_op⟩ → < | > | <= | >=

⟨eq_op⟩ → == | !=

⟨cond_op⟩ → && | ||

⟨literal⟩ → ⟨int_literal⟩ | ⟨char_literal⟩ | ⟨bool_literal⟩

⟨id⟩ → TOKEN_ID

⟨int_literal⟩ → ⟨decimal_literal⟩ | ⟨hex_literal⟩

⟨decimal_literal⟩ → TOKEN_DECIMALCONST

⟨hex_literal⟩ → TOKEN_HEXADECIMALCONST

⟨bool_literal⟩ → TOKEN_BOOLEANCONST

⟨char_literal⟩ → TOKEN_CHARCONST

⟨string_literal⟩ → TOKEN_STRINGCONST

۲ـ۴ خروجی تحلیلگر نحوی

همانگونه که پیش تر اشاره شد، چنانچه یک برنامه‌ی صحیح به تحلیلگر شما داده شود باید بتواند $Syntax\ Tree$ آن را استخراج کند و به صورت پیشوندی [۱] چاپ کند.

توجه داشته باشید به تحلیلگر شما یک آرگومان پاس داده می‌شود که اگر مقدار این آرگومان 1 باشد ، باید Token Name برای ترمینال‌ها نمایش داده شود و در صورتی که این آرگومان 0 باشد ، باید Token Value برای ترمینال‌ها چاپ شود.

بدین ترتیب ، تحلیلگر شما باید این آرگومان را به صورت زیر دریافت کند :

$ ./syntaxParser 0 or 1

خروجی تحلیلگر نحوی شما برای یک نمونه کد صحیح به صورت زیر خواهد بود :

Input Code :

```
class Program {
    int add(int a, int b){
        return a + b;
    }
    void main(){
        int a, b;
        a = 3;
        add(a);
    }
}
```

Analyzer Output (print by Token_Name):

```
<program> TOKEN_CLASS TOKEN_PROGRAMCLASS TOKEN_LCB <method_decl> <type>
TOKEN_INTTYPE <id> TOKEN_ID TOKEN_LP <type> TOKEN_INTTYPE <id> TOKEN_ID
TOKEN_COMMA <type> TOKEN_INTTYPE <id> TOKEN_ID TOKEN_RP <block> TOKEN_LCB
<statement> TOKEN_RETURN  <expr> <expr> <location> <id> TOKEN_ID <bin_op>
<arith_op> TOKEN_ARITHMATICOP <expr> <location> <id> TOKEN_ID
TOKEN_SEMICOLON TOKEN_RCB <method_decl> TOKEN_VOIDTYPE TOKEN_MAINFUNC
TOKEN_LP TOKEN_RP <block> TOKEN_LCB <var_decl> <type> TOKEN_INTTYPE <id>
TOKEN_ID TOKEN_COMMA <id> TOKEN_ID TOKEN_SEMICOLON <statement> <location>
<id> TOKEN_ID <assign_op> TOKEN_ASSIGNOP <expr> <literal> <int_literal>
<decimal_literal> TOKEN_DECIMALCONST TOKEN_SEMICOLON <statement>
<method_call> <method_name> <id> TOKEN_ID TOKEN_LP <expr> <location> <id>
TOKEN_ID TOKEN_RP TOKEN_SEMICOLON TOKEN_RCB TOKEN_RCB
```

[۱] Pre-Order

```
Analyzer Output (print by Token_Value):

    <program> class Program { <method_decl> <type> int <id> add ( <type> int
    <id> a , <type> int <id> b ) <block> { <statement> return  <expr> <expr>
    <location> <id> a <bin_op> <arith_op> + <expr> <location> <id> b ; }
    <method_decl> void main ( ) <block> { <var_decl> <type> int <id> a , <id> b
    ; <statement> <location> <id> a <assign_op> = <expr> <literal> <int_literal>
    <decimal_literal> 3 ; <statement> <method_call> <method_name> <id> add (
    <expr> <location> <id> a ) ; } }
```

خروجی تحلیلگر نحوی شما برای یک نمونه کد صحیح به صورت زیر خواهد بود :

```
Input Code :

    class Program {
        int globalVar;
        void main(){ }
    }


Analyzer Output (print by Token_Name):

    <program> TOKEN_CLASS TOKEN_PROGRAMCLASS TOKEN_LCB <field_decl> <type>
    TOKEN_INTTYPE <id> TOKEN_ID TOKEN_SEMICOLON <method_decl> TOKEN_VOIDTYPE
    TOKEN_MAINFUNC TOKEN_LP TOKEN_RP <block> TOKEN_LCB TOKEN_RCB TOKEN_RCB


Analyzer Output (print by Token_Value):

    <program> class Program {<field_decl> <type> int <id> globalVar ;
    <method_decl> void main ( ) <block> { } }
```

خروجی تحلیلگر نحوی شما برای یک نمونه کد حاوی خطا به صورت زیر خواهد بود :

```
Input Code :

    class Program {
        int globalVar
        void main(){ }
    }


Analyzer Output :

    syntax error in line 2 : [expected ; at the end of statement]
```

۲ـ۵ بخش امتیازی

نمایش $Syntax\ Tree$ به صورت دو بُعدی به شکل افقی یا عمودی، دارای نمره اضافه است.

به طور مثال، $Syntax\ Tree$ برای قطعه کد زیر، رسم شده است.

```
class Program {
    int globalVar;
    void main(){ }
}
```

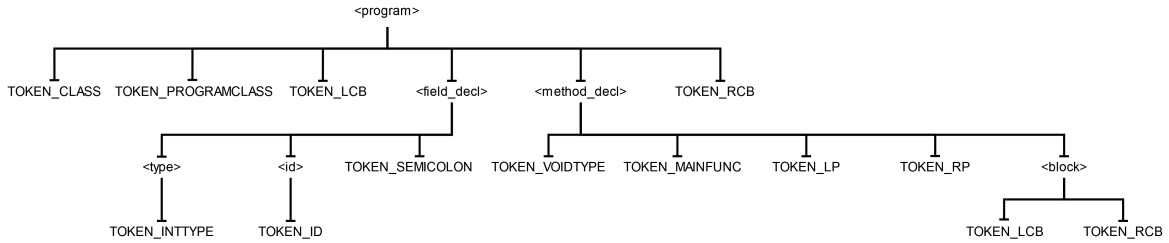

شکل ۲ـ۱: نمایش $Syntax\ Tree$ به صورت دو بُعدی به شکل عمودی برای نمونه کد فوق

فصل سوم

تحلیلگر معنایی و تولید کد

۳ـ۱ هدف

در فاز سوم و نهایی پروژه ، می‌بایست یک کامپایلر برای زبان $Xlang$ را با استفاده از ابزارهای $flex$ و $bison$ نوشته و در محل مشخص شده درون سامانه آپلود کنید.

لازم به یادآوری است که در فازهای قبلی ، توانستیم برنامه ورودی را از لحاظ ایرادهای لغوی و نحوی بررسی کنیم و Syntax Tree آن را رسم کنیم ؛ اما همانظور که می‌دانید وظیفه کامپایلر صرفاً به تولید Syntax Tree ختم نمی‌شود بلکه خروجی یک کامپایلر باید یک برنامه به زبان اسمبلی باشد.

برای تولید کد اسمبلی ، کافیست semantic action های فاز قبل را به گونه‌ای تغییر بدهید که منجر به تولید کد اسمبلی شود بنابراین در این فاز ، همان برنامه‌ای که برای فاز اول و دوم پروژه آماده کرده بودید را تکمیل خواهید کرد.

زبان اسمبلی که برای کد خروجی در نظر گرفته‌ایم ، زبان MIPS است. البته قصد نداریم که از دستورات پیچیده آن استفاده کنید و صرفاً آشنایی مقدماتی با آن برای انجام این فاز کافی است.

در انتهای این فاز ، برنامه شما مشابه یک کامپایلر واقعی عمل خواهد کرد به این صورت که بعد از دریافت یک فایل حاوی قطعه کدی به زبان $Xlang$ که قواعد لغوی، نحوی و معنایی زبان برنامه نویسی $Xlang$ را رعایت

کرده باشد، یک فایل به زبان MIPS تولید کند به نحوی که قابلیت اجرا در محیط SPIM[1] را داشته باشد و در غیر این صورت بدون تولید فایل خروجی و با نمایش خطای مربوطه خارج شود.
لازم به ذکر است که اگر برای اجرای کد خروجی کامپایلرتان در فضای SPIM ، به تعریف برخی ماکروها نیاز باشد بهتر است کامپایلر بتواند خودش آن‌ها را تولید کند.
برای فهم بهتر از چگونگی تعریف ماکرو ها در صورت نیاز می‌تونید به این لینک مراجعه کنید.

۳ـ۲ قواعد معنایی زبان

هنگام پیاده سازی بخش تحلیل معنایی، قواعد زیر را در نظر داشته باشید :

۳ـ۲ـ۱ قواعد Scope

زبان $Xlang$ قواعد scope ساده و محدودی دارد. تمام شناسه‌ها[2] باید قبل از استفاده ، تعریف شده باشند. به طور مثال :

- یک متغیر باید قبل از استفاده ، تعریف شده باشد.
- یک تابع را فقط می‌توان با کدی که بعد از header آن ظاهر می‌شود ، فراخوانی کرد.(پس توجه داشته باشید که توابع بازگشتی مجاز هستند.)

در هر نقطه از برنامه $Xlang$ حداقل دو scope معتبر وجود دارد : Global Scope و Method Scope.
global scope شامل اسامی متغیرها و توابعی هست که در کلاس **Program** تعریف شده‌اند و method scope شامل اسامی متغیرها و پارامترهایی است که در داخل بدنه‌ی یک تابع تعریف شده‌اند. علاوه بر این دو، local scope نیز در هر $\langle block \rangle$ در کد وجود دارد. این میتواند بعد از **if** و یا **for** بیاید و یا در هر جایی از یک $\langle statement \rangle$ اضافه شود.
همچنین توجه داشته باشید که یک شناسه در یک method scope می‌تواند همنام شناسه‌ای در global scope باشد و به صورت مشابه ، یک شناسه در local scope می‌تواند همنام شناسه‌ای در scope بالاتر (تابع یا سراسری) باشد که در این شرایط از شناسه‌ای که متعلق به همان scope هست استفادهِ می‌شود نه scope های بالاتر.به علاوه دقت کنید که هیچ شناسه‌ای نمی‌تواند بیش از یکبار در یک scope واحد تعریف شود.

---
[1] یک برنامه‌ی شبیه‌سازی برای اجرای کدهای MIPS است
[2] Identifiers

۳-۲-۲ Locations

زبان برنامه نویسی $Xlang$ دو نوع location دارد : متغیرهای اسکالر محلی/سراسری و آرایه‌های سراسری. هر location یک نوع دارد. location های از نوع داده **int** شامل مقادیر integer و location های از نوع داده **boolean** شامل مقادیر boolean هست تبعاً. Location هایی از انواع `int [N]` و `boolean [N]` نیز عناصر آرایه‌ای هستند. از آنجایی که آرایه‌ها سایز ثابتی دارند در فضای استاتیک داده‌های برنامه، حافظه می‌گیرند و نیازی به استفاده از heap ندارند.

هر location هنگامی که تعریف می‌شود به صورت دیفالت مقداردهی نیز می‌شود. اعداد صحیح به صورت دیفالت با صفر مقداردهی شده و boolean ها با مقدار **false**. همچنین متغیرهای محلی هنگاهی که خط اجرای برنامه به scope که در آن تعریف شده‌اند می‌رسد ، مقداردهی می‌شود و آرایه‌ها نیز هنگام شروع برنامه به صورت دیفالت مقداردهی می‌شوند.

۳-۲-۳ انتساب

انتساب فقط برای مقادیر اسکالر مجاز است. برای انواع داده **int** و **boolean** زبان $Xlang$ از قواعد value-copy استفاده می‌کند به بیان دیگر ، در انتساب $\langle location \rangle$ = $\langle expr \rangle$ مقدار معادل $\langle expr \rangle$ در $\langle location \rangle$ کپی می‌شود و یا در $\langle location \rangle$ += $\langle expr \rangle$ مقدار ذخیره شده در $\langle location \rangle$ به اندازه مقدار معادل $\langle expr \rangle$ افزایش خواهد یافت و این تنها زمانی معتبر است که $\langle expr \rangle$ و $\langle location \rangle$ هردو از نوع داده **int** باشند به صورت مشابه برای $\langle location \rangle$ -= $\langle expr \rangle$ مقدار ذخیره شده در $\langle location \rangle$ به اندازه مقدار معادل $\langle expr \rangle$ کاهش خواهد یافت و این تنها زمانی معتبر است که $\langle expr \rangle$ و $\langle location \rangle$ هردو از نوع داده **int** باشند.

در هر انتساب $\langle expr \rangle$ و $\langle location \rangle$ باید هردو از یک نوع داده باشند. برای آرایه‌ها، $\langle expr \rangle$ و $\langle location \rangle$ باید به یک عنصر خاص از آرایه که یک مقدار اسکالر است، اشاره داشته باشند.

بدیهی است که انتساب به پارامترهای داخل بدنه‌ی یک تابع نیز مجاز هست و این انتساب تنها در scope تابع تاثیرگذار هست.

۳-۲-۴ فراخوانی توابع و بازگشت

فراخوانی تابع شامل سه مرحله است :

۱. پاس دادن آرگومان‌ها از فراخوانی‌کننده[۱] به فراخوانی‌شده[۲]

۲. اجرای بدنه تابع

---

[۱] caller
[۲] callee

۳. بازگشت خط اجرا از فراخوانی شده به فراخوانی کننده، معمولاً همراه با یه مقدار بازگشتی.

پاس دادن آرگومان‌ها تحت عنوان انتساب انجام می‌شود به این صورت که پارامترهای رسمی تابع ، متغیرهایی در scope تابع تعریف می‌شوند و مقداردهی آنها با مقادیری که فراخوانی‌کننده به تابع میفرستد انجام می‌شود. مقداردهی آرگومان‌ها از چپ به راست انجام می‌شود.
سپس بدنه تابع خط به خط اجرا می‌شود.
تابعی که خروجی نداشته باشد (`void`) فقط می‌تواند به صورت یک جمله تنها استفاده شود و نباید در یک عبارت استفاده گردد. در این توابع وقتی خط اجرا به دستور **return** یا در صورت عدم وجود این دستور، به انتهای بدنه تابع می‌رسد، کنترل را به فراخوانی‌کننده برمی‌گرداند.
توابعی که مقداری را برمی‌گردانند، می‌توانند در یک عبارت استفاده شوند که در این صورت ، مقدار بازگردانده شده تابع در عبارت مذکور استفاده می‌شود. این توابع را می‌توان به صورت یک جمله تنها نیز استفاده کرد که در این صورت مقدار بازگردانده شده تابع، نادیده گرفته می‌شود.

۳ـ۲ـ۵ دستورات کنترلی

if

دستور **if** قاعده نحوی مشابه زبان برنامه نویسی C دارد. ابتدا $\langle expr \rangle$ ارزیابی می‌شود. اگر ارزش آن **true** باشد آنگاه بدنه‌ی **if** اجرا می‌شود در غیر این صورت ، بدنه‌ی **else** (در صورت وجود) اجرا می‌گردد. از آنجایی که در زبان $Xlang$ برای مشخص کردن بدنه **if** و **else** از کروشه استفاده می‌شود (حتی اگر بدنه هر یک از این دو دستور شامل تنها یک جمله باشد.) پس ابهامی در اینکه هر **else** متعلق به کدام **if** است پیش نخواهد آمد.

for

دستور **for** مشابه دستور **do** در زبان $Fortran$ می‌باشد. $\langle id \rangle$ همان اندیس حلقه است و نیازی نیست که قبلاً تعریف شده باشد (توجه داشته باشید که اگر قبل از حلقه متغیری با همان نام اندیس حلقه تعریف شده باشد، در بدنه حلقه از آن استفاده نمی‌شود و مقدار آن تغییر نخواهد کرد.). اندیس حلقه یک متغیر از نوع **int** است که scope آن محدود به حلقه نظیر آن می‌باشد. اولین $\langle expr \rangle$ مقدار آغازین اندیس حلقه و دومین $\langle expr \rangle$ مقدار نهایی اندیس حلقه را مشخص می‌کند. هر یک از این $\langle expr \rangle$ ها یکبار قبل از اجرای دستور حلقه، ارزیابی می‌شود. نوع هر یک از $\langle expr \rangle$ ها باید **int** باشد. بدنه‌ی حلقه زمانی اجرا می‌شود که مقدار فعلی اندیس حلقه از مقدار نهایی آن کمتر باشد. بعد از اجرای بدنه‌ی حلقه، مقدار اندیس یک واحد افزایش می‌یابد و مقدار جدید با مقدار نهایی مقایسه می‌شود تا بررسی شود آیا حلقه باید یک بار دیگر اجرا شود یا خیر.

۳ـ۲ـ۶ عبارات

عبارت‌ها از قواعد متداول و نرمال برای ارزیابی مقدار نهایی‌شان پیروی می‌کنند. در غیاب محدودیت‌های دیگر، عملگرهایی از یک سطح اولویت، از چپ به راست محاسبه می‌شوند. پرانتز بالاترین اولویت را دارد.
لیترال‌های صحیح معادل مقدار صحیح نظیرشان هستند و لیترال‌های کاراکتری معادل ارزش اسکی نظیرشان هستند مثلا 'A' بیانگر عدد صحیح 65 است.
جدول اولویت عملگرها از بالاترین به پایین‌ترین :

عملگرها	توضیحات
-	منفی تک‌عملوندی
!	not منطقی
* / %	باقیمانده، تقسیم، ضرب
+ -	تفریق، جمع
< <= >= >	رابطه‌ای
== !=	عدم تساوی، تساوی
&&	and شرطی
||	or شرطی

در فاز اول و دوم پروژه به ازای همه عملگرهای محاسباتی توکن یکسان TOKEN_ARITHMATICOP در نظر گرفته شد.
لیکن جهت تولید کد در این فاز نیاز است این عملگرها را تفکیک کرده و به ازای هر یک توکن جداگانه ای در نظر بگیرید. این کار را می توانید با ایجاد تغییرات بسیار اندک در فاز ۱ و ۲ انجام دهید. بدین ترتیب در این فاز با در نظرگیری توکن های زیر به گونه ای مناسب اولویت دهی به عملگرهای محاسباتی را درون گرامر لحاظ نمایید.

Token	***Token Name***
+	TOKEN_ARITHMATICOP_ADD
-	TOKEN_ARITHMATICOP_SUB
*	TOKEN_ARITHMATICOP_MUL
/	TOKEN_ARITHMATICOP_DIV

تقسیم بر 0 را چه به صورت صریح و چه به صورت غیرصریح کنترل کنید و در صورت وجود تقسیم بر 0 ، صرفاً یک هشدار چاپ کنید.(دقت کنید که خطایی تولید نمی‌شود یعتی کد اسمبلی تولید می‌شود و تنها یک هشدار به کاربر داده می‌شود.)

۳ـ۳ جمع‌بندی قواعد معنایی

این قوانین، محدودیت‌های بیشتری را روی برنامه‌های زبان $Xlang$ اعمال می‌کنند. هربرنامه‌ای که از نظر گرامر زبان، خوش‌ـفرم باشد و تناقضی با قوانین معنایی زیر نداشته باشد ، یک برنامه *legal* نامیده می‌شود. یک کامپایلر قدرتمند باید هریک از قوانین زیر را چک کرده و در صورت مواجه شدن با خطا ، پیغام ارور مناسب را چاپ نماید.

۱. هیچ شناسه‌ای در یک scope واحد ، دو بار تعریف نمی‌شود.

۲. هیچ شناسه‌ای پیش از تعریف شدن، استفاده نمی‌شود.

۳. برنامه شامل یک تابع به نام **main** است که هیچ پارامتر ورودی ندارد.(توجه داشته باشید از آنجایی که نقطه شروع برنامه‌های $Xlang$ تابع **main** است، پس هر تابعی که بعد از آن تعریف شود هیچگاه اجرا نخواهد شد.)

۴. در تعریف آرایه، اندازه آرایه باید بزرگتر از 0 باشد.

۵. در فراخوانی تابع، تعداد و نوع مقادیر پاس داده شده به تابع باید با تعداد و نوع آرگومان‌ها در تعریف تابع یکسان باشد.

۶. اگر در یک عبارت، فراخوانی تابع وجود داشت، آن تابع باید حتما خروجی داشته باشد و از نوع **void** نباشد.

۷. دستور **return** نباید شامل مقدار بازگشتی باشد مگر آنکه در تعریف تابع ، خروجی از نوع **int** یا **boolean** لحاظ شده باشد.

۸. نوع مقدار بازگشتی در دستور **return** باید با نوع خروجی در تعریف تابع یکی باشد.

۹. هرگاه $\langle id \rangle$ به عنوان $\langle location \rangle$ استفاده می‌شود باید قبلاً به عنوان یک متغیر سراسری یا محلی و یا پارامتر رسمی در تابع، تعریف شده باشد.

۱۰. برای هر location به فرم $\langle id \rangle$ [$\langle expr \rangle$]

(آ) $\langle id \rangle$ باید نام متغیری که بیانگر یک آرایه است، باشد و

(ب) نوع $\langle expr \rangle$ باید **int** باشد.

۱۱. نوع $\langle expr \rangle$ در دستور **if** باید **boolean** باشد.

۱۲. نوع عملوندهای عملگرهای محاسباتی و رابطه‌ای باید **int** باشد.

۱۳. نوع عملوندهای عملگرهای تساوی و عدم تساوی باید یکی باشد، یا **int** یا **boolean**.

۱۴. نوع عملوندهای عملگرهای شرطی و not منطقی (!) باید **boolean** باشد.

۱۵. در یک انتساب به فرم $\langle location \rangle$ = $\langle expr \rangle$ باید نوع $\langle expr \rangle$ و $\langle location \rangle$ یکی باشد.

۱۶. در یک انتساب افزایشی/کاهشی به فرم $\langle location \rangle$ += $\langle expr \rangle$ و $\langle location \rangle$ -= $\langle expr \rangle$ باید نوع $\langle location \rangle$ و $\langle expr \rangle$ **int** باشد.

۱۷. $\langle expr \rangle$ شروع و $\langle expr \rangle$ پایان حلقه‌ی **for** باید از نوع **int** باشند.

۱۸. تمام دستورات **break** و **continue** فقط باید در بدنه‌ی حلقه‌های **for** آمده باشند.

۱۹. اندیس آرایه حتماً باید در محدوده اندازه‌ی آرایه باشد.

۲۰. کنترل نباید بدون آنکه مقداری را بازگرداند به انتهای تابعی که باید خروجی داشته باشد، برسد .

۳ـ۴ تولید کد اسمبلی

برای پیاده سازی بخش تولید کد، به چند نکته توجه کنید :

۱. نگران پرش‌های با طول زیاد نباشید، فرض می‌شود که آدرس همه‌ی توابع و هاjump با هر دستور پرش قابل دسترس هستند.

۲. برای نگهداری آرایه‌ها و متغیرها از حافظه استاتیک استفاده کنید و نیاز به استفاده از heap نیست.

۳ـ۴ـ۱ نمونه سودوکدهای تولید کد اسمبلی

در ادامه چند نمونه از تبدیل ک ورودی به کد اسمبلی خروجی آورده شده است.

تذکر : این کدهای اسمبلی به زبان MIPS نیست و صرفاً جنبه سودوکد دارد تا شما با فرایند تولید کد آشنا شوید.

عملیات unary

```
Input Code :  -3
Pseudo Code:
    movl     $3, %eax; // EAX register contains 3
    neg      %eax;     // now EAX register contains -3
```

عملیات binary

در مثال زیر، ابتدا باید کدهای مربوط به $E1$ را تولید کنیم و مقدار آن را در استک ذخیره کنیم و سپس کدهای مربوط به $E2$ را تولید می‌کنیم و مقدار آن را نیز محاسبه می‌کنیم. حال مقدار $E1$ را از استک برداشته و عملیات جمع را انجام می‌دهیم.

```
Input Code :  E1 + E2
Pseudo Code:
    <CODE FOR E1 GOES HERE>
    push     %eax;       // save value of E1 on the stack
    <CODE FOR E2 GOES HERE>
    pop      %ecx;       // pop E1 from the stack into ECX register
    addl     %ecx, %eax; // add E1 to E2, save results in EAX
```

عملیات binary اتصال کوتاه

عملیات‌هایی مثل && و || که ممکن است نیازی به اجرای کل دستور نباشد را در این دسته قرار میدهیم. همان مراحل قبل را طی می‌کنیم با این تفاوت که اگر پس از محاسبه‌ی $E1$ نتیجه محاسبات به صورت قطعی تعیین گردد پس دیگر نیازی به محاسبه‌ی $E2$ نیست و به سراغ کامپایل خط بعدی در برنامه می‌رویم.

```
Input Code :  E1 || E2

Pseudo Code:

        <CODE FOR E1 GOES HERE>
        cmpl     $0, %eax; // check if E1 is true
        je       _clause2; // E1 is 0, so we need to evaluate clause 2
        movl     $1, %eax; // we didn't jump, so E1 is true and therefore result is 1
        jmp      _end;
    _clause2:
        <CODE FOR E2 GOES HERE>
        cmpl      $0, %eax; // check if E2 is true
        movl      $0, %eax; // zero out EAX without changing 2F
        setne     %al;      // set AL register (the low byte of EAX) to 1 iff E2 != 0
    _end:
        jmp       _end;
```

عبارت‌های شرطی

مقدار $E1$ را محاسبه کرده و آن را با 0 مقایسه می‌کنیم چنانچه برابر با صفر بود آنگاه کد مربوط به قسمت **else** باید اجرا گردد و در غیر این صورت، تنها کد مربوط به $E2$ باید انجام شود.

```
Input Code :  if (E1) { E2 } else { E3 }

Pseudo Code:

        <CODE FOR E1 GOES HERE>
        cmpl      $0, %eax;
        je        _E3; // if (E1) == 0, E1 is false so execute E3
        <CODE FOR E2 GOES HERE> // we're still here so E1 must be true. execute E2.
        jmp       _post_conditional; // jump over E3
    _E3:
        <CODE FOR E3 GOES HERE> // we jumped here because E1 was false. execute E3.
    _post_conditional: // we need this label to jump over E3
```

فراخوانی تابع

- توابع موجود در کلاس **Program** :

```
Input Code :  foo(1, 2, 3)

Pseudo Code:

        push      $3; // save parameters in registers/stack
        push      $2;
        push      $1;
        call      _foo; // call method
        add       $0xC, $esp; // remove input arguments from stack
    _foo:
```

```
push      %ebp; // Save the stack start address corresponding to the
                // caller function
mov       $esp, $ebp; // initialize stack for foo function
<DO STUFF> // execute function body
mov       %ebp, %esp; // Delete all variables taken from the stack
                      // during function execution
pop       %ebp; // Restore stack information related to caller function
ret; // return to previous function
```

- توابع آماده از کتابخانه‌ها مختلف با استفاده از **callout** :

```
Input Code :  callout("atoi", "12");

Pseudo Code:
    push      $0x3132; // ascii code for "12" is 0x3132
    call      atoi;
```

۳ـ۵ خروجی تولیدکننده کد

خروجی چند نمونه کد اسمبلی MIPS به صورت زیر می باشد. لازم به ذکر است خروجی کد اسمبلی نظیر یک برنامه نوشته شده به زبان سطح بالا، لزوما یکتا نیست.

نمونه اول:

```
Input Code :
    class Program{
        void main(){
            int s=3;
            int k=9;
            k=k+s;
        }
     }

Output Code:
    .globl main
    main:
        addi  $s0, $zero, 3
        addi  $s1, $zero, 9
        add  $t0, $s1, $s0
        move  $s1, $t0
        li  $v0, 10
        syscall
```

نمونه دوم:

Input Code :

```
class Program{
    int func(int a,int b){
        return a+b;
    }
    void main(){
        int t;
        t = func(3, 7);
    }
}
```

Output Code:

```
.globl main
func:
    add  $t0, $a0, $a1
    move  $v0, $t0
    jr  $ra
main:
    addi  $a0, $zero, 3
    addi  $a1, $zero, 7
    jal  func
    move  $s0, $v0
    li  $v0, 10
    syscall
```

نمونه سوم:

Input Code :

```
class Program{
    void main(){
        int k;
        k = 5 * 3 + 6 / 2;
        int t;
        t = (k - 10) * 4 + 2 - (2 * 3);
    }
}
```

Output Code:

```
.globl main
main:
    addi  $t0, $zero, 15
    addi  $t1, $zero, 3
    add  $t2, $t0, $t1
    move $s0, $t2
    addi $t0, $s0, -10
    addi $t1, $zero, 4
```

```
        mul  $t1, $t0, $t1
        addi $t0, $t1, 2
        addi $t1, $zero, 6
        sub  $t2, $t0, $t1
        move $s1, $t2
        li  $v0, 10
        syscall
```

نمونه چهارم:

Input Code :

```
    class Program{
        void main(){
            int k;
            k = 9;
            for i = 0, 5 {
                k = k + 1;
            }
        }
    }
```

Output Code:

```
    .globl main
    main:
        addi  $s0, $zero, 9
        addi  $s1, $zero, 0
    LOOP1:
        addi  $t0, $zero, 5
        slt   $t0, $s1, $t0
        beq   $t0, $zero, L1
        addi  $t1, $s0, 1
        move  $s0, $t1
        addi  $t1, $s1, 1
        move $s1, $t1
        j  LOOP1
    L1:
        li  $v0, 10
        syscall
```

۱ـ۱ پیوست ۱

Token	*Token Name*
boolean	TOKEN_BOOLEANTYPE
break	TOKEN_BREAKSTMT
callout	TOKEN_CALLOUT
class	TOKEN_CLASS
continue	TOKEN_CONTINUESTMT
else	TOKEN_ELSECONDITION
false	TOKEN_BOOLEANCONST
for	TOKEN_LOOP
if	TOKEN_IFCONDITION
int	TOKEN_INTTYPE
return	TOKEN_RETURN
true	TOKEN_BOOLEANCONST
void	TOKEN_VOIDTYPE
Program	TOKEN_PROGRAMCLASS
main	TOKEN_MAINFUNC
⟨variables⟩	TOKEN_ID
+	TOKEN_ARITHMATICOP
-	TOKEN_ARITHMATICOP
*	TOKEN_ARITHMATICOP
/	TOKEN_ARITHMATICOP
%	TOKEN_ARITHMATICOP
&&	TOKEN_CONDITIONOP
||	TOKEN_CONDITIONOP
<=	TOKEN_RELATIONOP
<	TOKEN_RELATIONOP
>	TOKEN_RELATIONOP
>=	TOKEN_RELATIONOP
!=	TOKEN_EQUALITYOP
==	TOKEN_EQUALITYOP
=	TOKEN_ASSIGNOP
+=	TOKEN_ASSIGNOP
-=	TOKEN_ASSIGNOP
!	TOKEN_LOGICOP
(	TOKEN_LP
)	TOKEN_RP
{	TOKEN_LCB
}	TOKEN_RCB
[	TOKEN_LB
]	TOKEN_RB
;	TOKEN_SEMICOLON
,	TOKEN_COMMA
\n [newline]	TOKEN_WHITESPACE
\t [tab]	TOKEN_WHITESPACE
[space]	TOKEN_WHITESPACE
//[some string until \n]	TOKEN_COMMENT
3 [or other decimal integers]	TOKEN_DECIMALCONST
0xFF [or other hexadecimal integers]	TOKEN_HEXADECIMALCONST
"[some string]"	TOKEN_STRINGCONST
'a'[or other characters]	TOKEN_CHARCONST